



**T.C.
KASTAMONU ÜNİVERSİTESİ
MÜHENDİSLİK VE MİMARLIK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**

Makine Öğrenmesi Ders Projesi

KONU

Beyin MRI Görüntülerinde Tümörlü ve Sağlıklı Dokuların Makine ve Derin Öğrenme Yöntemleriyle Sınıflandırılması

HAZIRLAYAN

234410090 – Muhammed Doğru

DANIŞMAN

Kemal Akyol

Aralık-2025
KASTAMONU

ÖZET

Final Ödevi

Beyin MRI Görüntülerinde Tümörlü ve Sağlıklı Dokuların Makine ve Derin Öğrenme Yöntemleriyle Sınıflandırılması

Muhammed Doğru

Kastamonu Üniversitesi

Bilgisayar Mühendisliği Bölümü

Danışman: Doç. Dr. Kemal AKYOL

Aralık 2025,20 sayfa

Bu çalışmada, beyin tümörü MRI görüntülerinin otomatik olarak sınıflandırılması problemi ele alınmıştır. Çalışma kapsamında, klasik makine öğrenmesi algoritmaları ile derin öğrenme tabanlı bir evrişimli sinir ağı modeli karşılaştırmalı olarak incelenmiştir. Deneylerde, toplam 7023 MRI görüntüsünden oluşan ve dört farklı sınıfı (Glioma, Meningioma, Pituitary ve No Tumor) içeren bir veri seti kullanılmıştır.

Klasik makine öğrenmesi yöntemleri için görüntüler öznitelik vektörlerine dönüştürülerek çeşitli sınıflandırma algoritmaları uygulanmış, derin öğrenme yaklaşımı olarak ise transfer öğrenme temelli EfficientNetB0 mimarisi tercih edilmiştir. Model performansları; doğruluk, duyarlılık, özgüllük, F1-skoru, ROC eğrileri ve McNemar testi gibi değerlendirme metrikleri kullanılarak analiz edilmiştir.

Ayrıca, geliştirilen sınıflandırma modellerinin kullanıcı tarafından kolayca test edilebilmesi amacıyla, MRI görüntülerinin yüklenmesine ve tahmin sonuçlarının görsel olarak sunulmasına olanak sağlayan bir grafik kullanıcı arayüzü tasarlanmıştır. Bu arayüz sayesinde, seçilen bir MRI görüntüsü için model tahminleri ve sınıf olasılıkları kullanıcıya anlaşılır bir biçimde gösterilmektedir.

Anahtar Kelimeler: Beyin tümörü, MRI görüntüleri, makine öğrenmesi, derin öğrenme, EfficientNetB0, sınıflandırma

İÇİNDEKİLER

1. GİRİŞ

- 1.1 Projenin Amacı ve Önemi
- 1.2 Beyin Tümörü Tespiti Neden Önemli?
- 1.3 MRI Görüntüleri ve Sınıflandırmanın Sağlık Alanındaki Rolü

2. LİTERATÜR TARAMASI

3. DENEYSEL ÇALIŞMALAR

- 3.1 Veri Seti Tanımı
 - 3.1.1 Veri Dağılımı ve İstatistiksel Bilgiler
 - 3.1.2 Sınıf Tanımları
- 3.2 Veri Ön İşleme
 - 3.2.1 Klasik Makine Öğrenmesi İçin Ön İşleme
 - 3.2.2 Derin Öğrenme (CNN) İçin Ön İşleme ve Veri Artırma
- 3.3 Doğrulama Yöntemleri
- 3.4 Sınıflandırma Modelleri
 - 3.4.1 Klasik Makine Öğrenmesi Modelleri
 - 3.4.2 Derin Öğrenme Modeli: EfficientNetB0 (CNN)
- 3.5 Yapay Sinir Ağları İçin Eğitim ve Kayıp Grafikleri
 - 3.5.1 Birinci Aşama: Transfer Learning (Özellik Çıkarımı)
 - 3.5.2 İkinci Aşama: Fine-Tuning
- 3.6 Karışıklık Matrisleri
 - 3.6.1 Hold-Out
 - 3.6.2 K-Fold
- 3.7 Doğruluk, Duyarlılık, Özgüllük ve F1-Skoru Sonuçları
 - 3.7.1 Sınıflandırıcıların Genel Performans Metriklerinin Karşılaştırılması (Hold-Out)
 - 3.7.2 Sınıflandırıcıların Genel Performans Metriklerinin Karşılaştırılması (K-Fold)
- 3.8 Alıcı-İşlem Karakteristiği (ROC) Sonuçları
 - 3.8.1 Hold-Out
 - 3.8.2 K-Fold
- 3.9 McNemar Testi Sonuçları
 - 3.9.1 Hold-Out
 - 3.9.2 K-Fold

4. TARTIŞMA VE SONUÇ

- 4.1 Tartışma
- 4.2 Sonuç

5. KAYNAKÇA

1. GİRİŞ

1.1 Projenin Amacı ve Önemi

Bu projenin amacı, beyin tümörü MRI görüntülerini kullanarak farklı tümör tiplerini ve normal beyin dokusunu otomatik olarak sınıflandıracak bir derin öğrenme modeli geliştirmektir. Beyin tümörleri, erken teşhis edilmediğinde ciddi sağlık sorunlarına yol açabilir ve tedavi süreci gecikebilir. Yapay zekâ destekli sınıflandırma sistemleri, uzman radyologların iş yükünü azaltarak daha hızlı ve doğru tanı konmasına yardımcı olabilir.

1.2 Beyin Tümörü Tespiti Neden Önemli?

Beyin tümörleri, genellikle yaşamı tehdit eden ciddi hastalıklardır ve erken teşhis, tedavi başarısı açısından kritik öneme sahiptir. Geleneksel yöntemler, radyologların MRI görüntülerini manuel olarak incelemesine dayanır ve zaman alıcıdır. Yanlış veya gecikmiş tanı, tedavi sürecini olumsuz etkileyebilir ve hastanın yaşam kalitesini düşürebilir. Bu nedenle otomatik sınıflandırma sistemleri, tanı sürecinin doğruluğunu ve hızını artırmak açısından büyük önem taşımaktadır.

1.3 MRI Görüntüleri ve Sınıflandırmanın Sağlık Alanındaki Rolü

MRI (Manyetik Rezonans Görüntüleme), beyin dokusunun detaylı ve yüksek çözünürlüklü görüntülerini sağlayan invaziv olmayan bir yöntemdir. MRI görüntüleri, tümörün boyutu, tipi ve konumu hakkında değerli bilgiler sunar. Yapay zekâ ve derin öğrenme teknikleri kullanılarak MRI görüntülerinin sınıflandırılması, tanı sürecini otomatikleştirir, hataları azaltır ve hastalara hızlı bir şekilde uygun tedavi planı sunulmasını sağlar. Böylece sağlık hizmetlerinde hem doğruluk hem de verimlilik artışı sağlanır.

2. Literatür Taraması

Beyin tümörlerinin manyetik rezonans (MRI) görüntüleri üzerinden otomatik olarak sınıflandırılması, son yıllarda derin öğrenme yöntemlerinin gelişmesiyle birlikte yoğun biçimde araştırılmaktadır. Literatürde yapılan çalışmalar, özellikle konvolüsyonel sinir ağlarının (CNN) geleneksel makine öğrenmesi yöntemlerine kıyasla daha yüksek doğruluk oranları sunduğunu göstermektedir.

Wong ve arkadaşları, çok sınıflı beyin tümörü MRI görüntülerinin sınıflandırılması amacıyla VGG16 tabanlı bir derin öğrenme modeli önermiştir. Çalışmada glioma, meningioma, pituitary tümörleri ve sağlıklı beyin görüntüleri kullanılmış ve transfer learning yaklaşımı sayesinde %97.3 doğruluk oranı elde edilmiştir [1]. Bu sonuçlar, önceden eğitilmiş modellerin tıbbi görüntü sınıflandırmasında etkinliğini ortaya koymaktadır.

Rasheed ve arkadaşları, CNN tabanlı bir model geliştirmiş ve MRI görüntülerine histogram eşitleme gibi ön işleme teknikleri uygulamıştır. Önerilen yaklaşım %96.1 doğruluk oranına ulaşmış, görüntü iyileştirmenin sınıflandırma performansını olumlu yönde etkilediği belirtilmiştir [2]. Aynı yazarların başka bir çalışmasında CNN, SVM ve KNN algoritmaları karşılaştırılmış, CNN tabanlı modelin %95.8 doğruluk oranı ile klasik makine öğrenmesi yöntemlerine üstünlük sağladığı raporlanmıştır [3].

Derin öğrenme yaklaşımlarının genel performansını değerlendiren kapsamlı bir derleme çalışmasında, Dorfner ve arkadaşları CNN, ResNet ve DenseNet mimarilerinin beyin tümörü MRI analizinde yaygın olarak kullanıldığını ve doğruluk oranlarının genellikle %90 ile %99 arasında değiştiğini belirtmiştir [4].

Shahin ve arkadaşları, fine-tuning uygulanmış ResNet34 mimarisi ile çok sınıflı MRI görüntülerini sınıflandırmış ve %98.4 doğruluk oranı elde etmiştir [5]. Benzer şekilde Shoaib ve arkadaşları, EfficientNetB5, DenseNet201 ve InceptionResNetV2 gibi önceden eğitilmiş modelleri karşılaştırmış ve EfficientNetB5 modelinin %99.1 doğruluk oranı ile en iyi performansı gösterdiğini raporlamıştır [6].

Ahmed ve arkadaşları, CNN modelini veri artırma teknikleri ile destekleyerek overfitting problemini azaltmış ve %97.8 doğruluk oranı elde etmiştir [7]. Çalışma, özellikle sınırlı veri setleri üzerinde veri artırmanın önemini vurgulamaktadır.

Chatterjee ve arkadaşları, 3D MRI hacimlerini kullanarak ResNet(2+1)D tabanlı bir 3D CNN modeli önermiştir. Önerilen yöntem %96.9 doğruluk oranı elde etmiş ve üç boyutlu uzamsal bilginin sınıflandırma başarısını artırdığı gösterilmiştir [8].

Kaifi ve arkadaşları, CNN tabanlı yöntemlerle birlikte el yapımı özelliklerin kullanıldığı hibrit yaklaşımları incelemiş ve bu yöntemlerin %95–%98 aralığında doğruluk sağladığını raporlamıştır [9].

Zarenia ve arkadaşları ise segmentasyon ve sınıflandırma adımlarını birlikte ele alan bir CNN tabanlı yaklaşım önermiştir. Segmentasyon destekli model ile %98.9 doğruluk oranı elde edilmiş ve tümör bölgesine odaklanmanın sınıflandırma performansını artırdığı belirtilmiştir [10].

Özellikle hafif derin öğrenme mimarilerine odaklanan Diaz-Pernas ve arkadaşları, MobileNet tabanlı bir CNN modeli ile beyin tümörü MRI görüntülerini sınıflandırmış ve %96.5 doğruluk oranı elde etmiştir. Çalışma, düşük hesaplama maliyetiyle yüksek performans elde edilebileceğini göstermektedir [11].

Ayrıca Afshar ve arkadaşları, Capsule Network (CapsNet) tabanlı bir yaklaşım kullanarak MRI görüntülerinden beyin tümörü sınıflandırması gerçekleştirmiştir. Önerilen yöntem, uzamsal hiyerarşiyi daha iyi modelleyerek %97 civarında doğruluk oranı elde etmiş ve klasik CNN mimarilerine alternatif bir yapı sunmuştur [12]

3. Deneysel Çalışmalar

3.1 Veri Seti Tanımı:

Bu çalışmada kullanılan veri seti, beyin tümörlerinin bilgisayar destekli teşhisi için hazırlanan ve toplam **7023** adet MRI görüntüsünden oluşan kapsamlı bir veri setidir[13]. Veri seti, modelin başarısını tarafsız bir şekilde ölçebilmek amacıyla "Training" (Eğitim) ve "Testing" (Test) olarak iki bağımsız ana bölüme ayrılmıştır.

3.1.1 Veri Dağılımı ve İstatistiksel Bilgiler

Veri setindeki görüntülerin sınıflara göre sayısal dağılımı Tablo 3.1'de sunulmuştur:

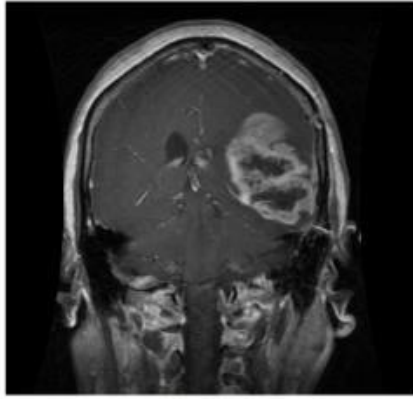
Tablo 3.1: Veri Seti Görüntü Sayıları ve Dağılımı

Sınıf Adı	Eğitim (Training)	Test (Testing)	Toplam
Glioma	1321	300	1621
Meningioma	1339	306	1645
Pituitary	1457	300	1757
No Tumor	1595	405	2000
GENEL TOPLAM	5712	1311	7023

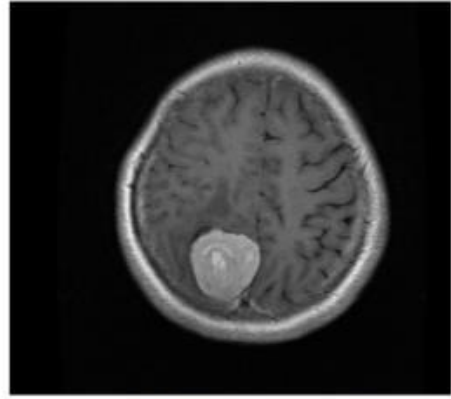
3.1.2 Sınıf Tanımları:

Çalışmada kullanılan görüntüler, aşağıda detaylandırılan üç tümör tipi ve bir sağlıklı kontrol grubunu temsil etmektedir:

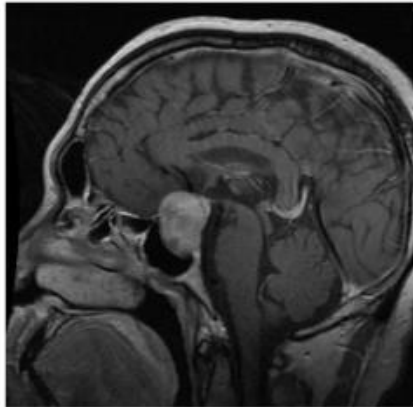
- **Glioma (Gliom):** Beyin ve omurilikteki destek dokusunu oluşturan glial hücrelerden kaynaklanan tümörlerdir. En yaygın birincil beyin tümörlerinden biri olup hızlı yayılım gösterebilirler.
- **Meningioma (Menenjiyom):** Beyni ve omuriliği çevreleyen zarlardan (meninks) kaynaklanan tümörlerdir. Genellikle yavaş büyürler ancak beyin dokusuna baskı yaparak ciddi semptomlara yol açabilirler.
- **Pituitary (Hipofiz):** Beynin tabanında bulunan hipofiz bezinde gelişen tümörlerdir. Bu tümörler genellikle iyi huylu olsa da vücudun hormonal dengesini bozabilir ve görme sinirlerine baskı yapabilir.
- **No Tumor (Tümör Yok):** Bu sınıf, herhangi bir patolojik bulgu içermeyen sağlıklı bireylere ait MRI görüntülerini içerir. Modelin tümörlü dokuyu sağlıklı dokudan ayırt etmeyi öğrenmesi için kritik öneme sahiptir.



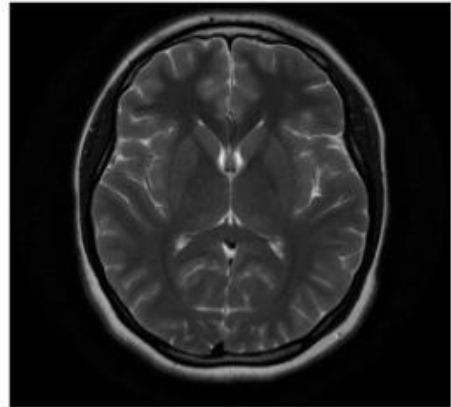
(a) Glioma



(b) Meningioma



(c) Pituitary



(d) No Tumor

3.2 Veri Ön İşleme

3.2.1 Klasik Makine Öğrenmesi İçin Ön İşleme

Logistic Regression, Random Forest, SVM gibi klasik algoritmalar için görüntüler düşük boyutlu vektörlere dönüştürülmüştür:

- **Yeniden Boyutlandırma (Resizing):** MRI cihazlarından gelen görüntüler farklı boyutlara sahiptir. Modellerin giriş standardını sağlamak ve işlem süresini optimize etmek için tüm görüntüler **64x64** piksel boyutuna getirilmiştir.
- **Normalizasyon (Ölçekleme):** Piksel değerleri 0 ile 255 arasındadır. Sayısal hesaplamaların kararlılığını artırmak için tüm değerler 255'e bölünerek **[0, 1]** aralığına çekilmiştir.
- **Renkli Görüntü İşleme (RGB):** Görüntüler 3 kanallı (renkli) olarak yüklenmiş, böylece tümör dokusundaki ince renk değişimleri ve doku detayları korunmuştur.
- **Düzleştirme (Flattening):** Kullanılan klasik makine öğrenmesi modelleri (Random Forest, SVM vb.) 2 boyutlu matrisleri doğrudan işleyemediği için 64x64x3 boyutundaki veriler **12.288** birimden oluşan tek boyutlu bir öznitelik vektörüne dönüştürülmüştür.

3.2.2. Derin Öğrenme (CNN) İçin Ön İşleme ve Veri Artırma

CNN modeli olarak **EfficientNetB0** mimarisi kullanıldığı için daha gelişmiş teknikler uygulanmıştır:

- **Yüksek Çözünürlük:** Modelin mimari gereksinimlerine ve daha ince detayları yakalayabilmesine olanak sağlamak için görüntüler **224x224** boyutunda işlenmiştir.
- **Veri Artırma (Data Augmentation):** Modelin sınırlı veri ile daha iyi genelleme yapabilmesi ve aşırı öğrenmeyi (overfitting) önlemek amacıyla eğitim sırasında görüntülere rastgele yatay çevirme (horizontal flip), %10 oranında döndürme (rotation) ve yakınlaştırma (zoom) işlemleri uygulanmıştır.

3.3 Doğrulama Yöntemleri

Bu çalışmada modellerin performansını tarafsız şekilde değerlendirmek amacıyla iki farklı doğrulama yöntemi kullanılmıştır. İlk olarak dışarıda tutma (hold-out) yöntemi uygulanmış ve veri seti %80 eğitim, %20 test olacak şekilde ayrılmıştır.

İkinci olarak modellerin genellenebilirliğini değerlendirmek için k-kat çapraz doğrulama yöntemi kullanılmıştır. Bu çalışmada k=5 olarak belirlenmiş ve her katmanda performans metrikleri hesaplanarak ortalamaları raporlanmıştır.

3.4 Sınıflandırma Modelleri

Bu çalışmada beyin tümörü teşhisi için iki ana grupta modeller incelenmiştir. İlk grupta verinin boyutu düşürülerek (flattening) geleneksel makine öğrenmesi algoritmaları test edilmiş, ikinci grupta ise derin öğrenme temelli transfer öğrenme (Transfer Learning) metoduyla modern bir CNN mimarisi olan EfficientNetB0 kullanılmıştır.

3.4.1 Klasik Makine Öğrenmesi Modelleri

Klasik modeller, görüntülerin piksellerini doğrudan birer öznitelik olarak kabul eden vektörler üzerinde çalıştırılmıştır. Kullanılan yedi farklı algoritmanın temel özellikleri şöyledir:

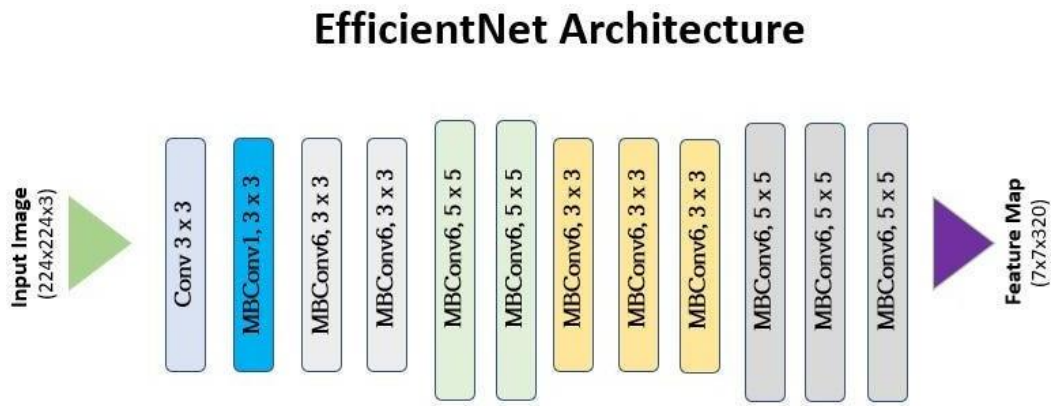
1. **Lojistik Regresyon (Logistic Regression):** Çok sınıflı sınıflandırma (One-vs-Rest) yaklaşımıyla, veriler arasındaki doğrusal ilişkileri modellemek için kullanılmıştır. Karmaşıklığı düşük, hızlı bir baz model (baseline) oluşturmuştur.
2. **K-En Yakın Komşu (K-Nearest Neighbors - KNN):** Yeni bir görüntüyü, eğitim setindeki en yakın komşularının sınıflarına göre etiketler. Öklid mesafesi kullanılarak komşuluk ilişkileri analiz edilmiştir.
3. **Destek Vektör Makineleri (SVM):** Verileri sınıflarına göre ayırmak için yüksek boyutlu uzayda optimal hiper-düzlemler oluşturur. Bu projede karmaşık sınırlardaki ayrımı yapabilmek için doğrusal olmayan **RBF (Radial Basis Function)** çekirdeği tercih edilmiştir.
4. **Naive Bayes (Gaussian):** Özniteliklerin bağımsız olduğunu varsayan olasılıksal bir modeldir. Görüntü piksellerinin normal dağıldığı varsayımıyla Gaussian sürümü uygulanmıştır.
5. **Karar Ağaçları (Decision Tree):** Veri setini belirli özellik eşiklerine göre (Gini impurity veya Entropy) dallara ayırarak karar kuralları oluşturur.
6. **Rastgele Orman (Random Forest):** Birden fazla karar ağacının sonuçlarını birleştiren (Ensemble) bir topluluk öğrenmesi modelidir. Bu çalışmada **200 ağaç** kullanılarak hem doğruluk artırılmış hem de aşırı öğrenme (overfitting) riski minimize edilmiştir.
7. **AdaBoost (Adaptive Boosting):** Zayıf öğrenicileri (genellikle sık karar ağaçlarını) ağırlıklandırarak bir araya getirir ve her adımda bir önceki hataya odaklanarak performansı iyileştirir.

3.4.1. Derin Öğrenme Modeli: EfficientNetB0 (CNN)

EfficientNetB0, Google tarafından önerilen ve evrimsel sinir ağlarında yüksek doğruluk ile düşük hesaplama maliyetini aynı anda hedefleyen bir derin öğrenme mimarisidir. EfficientNet ailesinin temel modeli olan EfficientNetB0, ağın derinliği (depth), genişliği (width) ve giriş çözünürlüğünü (resolution) dengeli bir şekilde ölçeklendiren bileşik ölçekleme (compound scaling) yaklaşımına dayanmaktadır. Bu sayede geleneksel CNN mimarilerine kıyasla daha az parametre kullanarak benzer veya daha yüksek performans elde edebilmektedir.

Şekil 3.4.2.1’te EfficientNetB0 mimarisinin genel yapısı ve katman blokları gösterilmektedir. Bu mimari, giriş katmanından itibaren farklı çözünürlük seviyelerinde özellik haritaları üreterek, görüntüdeki hem düşük seviyeli hem de yüksek seviyeli yapısal bilgilerin etkili bir biçimde öğrenilmesini sağlar. EfficientNetB0, özellikle sınırlı veri setleri ve medikal görüntüleme uygulamaları için uygun bir yapı sunmaktadır.

3.4.1.1



3.4.1.2 EfficientNetB0 Tabanlı Özelleştirilmiş CNN Mimarisi

Katman Grubu	İşlev ve Parametreler	İşlevi
Giriş	Input(shape=(224,224,3))	Beyin MRI görüntülerini modele giriş olarak alır.
Veri Artırma	RandomFlip, RandomRotation, RandomZoom, RandomContrast	Eğitim sırasında görüntüleri rastgele dönüştürerek veri çeşitliliğini artırır ve aşırı öğrenmeyi azaltır.
Ön İşleme / Ölçekleme	Lambda(preprocess_input)	Piksel değerlerini EfficientNetB0 mimarisinin beklediği normalize edilmiş aralığa dönüştürür.
Ana Gövde (Backbone)	EfficientNetB0 (include_top=False)	MBConv ve Squeeze-and-Excitation blokları ile derin ve ayırt edici özellik çıkarımı yapar.
Özellik Özetleme	GlobalAveragePooling2D()	Uzamsal özellik haritalarını tek boyutlu öznitelik vektörüne indirger.
Stabilizasyon	BatchNormalization()	Aktivasyonları normalize ederek eğitimi hızlandırır ve model kararlılığını artırır.
Ara Karar Katmanı	Dense(256, activation="relu")	Çıkarılan özellikler arasında doğrusal olmayan ilişkiler kurar.
Düzenleştirme	Dropout(0.5)	Nöronların %50'sini rastgele devre dışı bırakarak overfitting'i önler.
Çıkış Katmanı	Dense(4, activation="softmax")	Glioma, Meningioma, Pituitary ve No Tumor sınıfları için olasılık üretir.

EfficientNetB0 mimarisi özellik çıkarıcı (backbone) olarak kullanılmış ve sınıflandırma problemine özgü katmanlar modele eklenmiştir. Giriş görüntüleri öncelikle veri artırma (data augmentation) işlemlerine tabi tutularak modelin genelleme yeteneği artırılmıştır. Ardından, EfficientNetB0 tarafından çıkarılan derin özellikler Global Average Pooling katmanı ile özetlenmiş ve Batch Normalization ile eğitim süreci stabilize edilmiştir.

Sınıflandırma aşamasında, çıkarılan özellikler arasında doğrusal olmayan ilişkilerin öğrenilebilmesi amacıyla ReLU aktivasyonlu Dense katmanı kullanılmıştır. Aşırı öğrenmenin önüne geçmek için Dropout tekniği uygulanmış ve son olarak dört sınıflı beyin tümörü problemine uygun olacak şekilde softmax aktivasyonlu çıkış katmanı ile sınıflandırma işlemi gerçekleştirilmiştir.

Bu yaklaşım sayesinde EfficientNetB0'ın güçlü özellik çıkarma kapasitesi korunmuş, problem özelinde daha etkili ve dengeli bir sınıflandırma modeli elde edilmiştir.

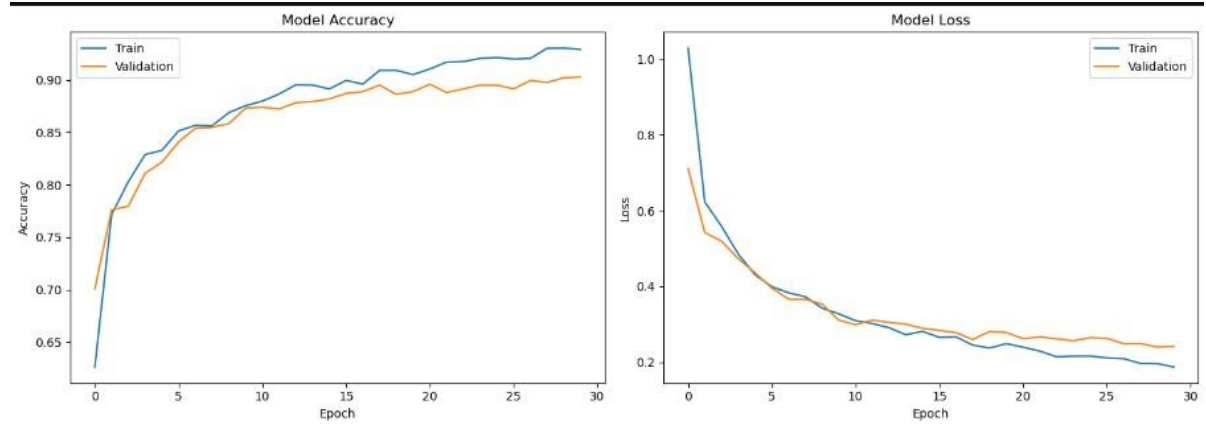
3.5 Yapay Sinir Ağları İçin Eğitim ve Kayıp Grafikleri

Bu çalışmada kullanılan EfficientNetB0 modeli, transfer öğrenme yaklaşımı doğrultusunda iki aşamalı olarak eğitilmiştir. Eğitim sürecinin her iki aşamasında da modelin öğrenme davranışı, eğitim ve doğrulama verileri üzerinden elde edilen kayıp (loss) ve doğruluk (accuracy) değerleri ile analiz edilmiştir.

3.5.1 Birinci Aşama: Transfer Learning (Özellik Çıkarımı)

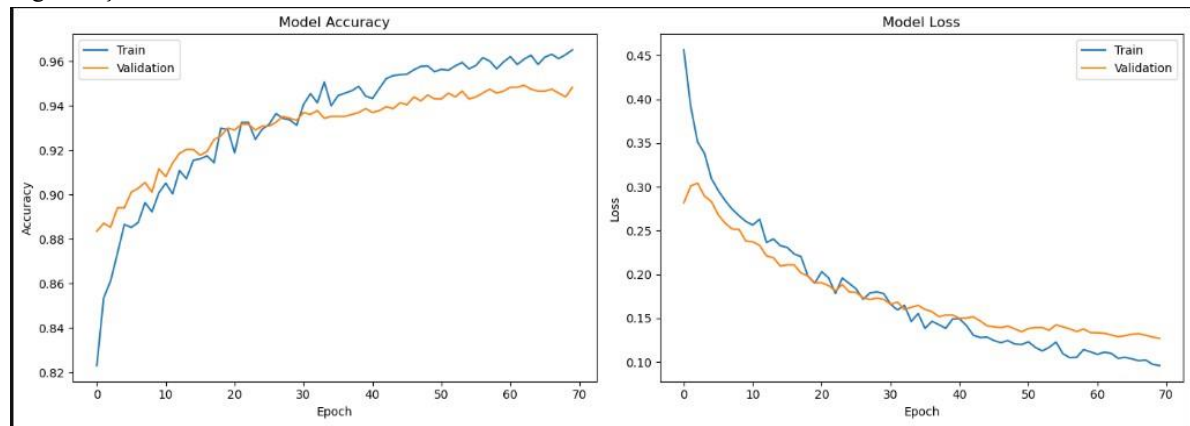
Birinci aşamada, EfficientNetB0 mimarisinin ImageNet veri kümesi üzerinde önceden öğrenilmiş evrişimli katmanları dondurulmuş ve bu katmanlar sabit özellik çıkarıcı (feature extractor) olarak kullanılmıştır. Bu aşamada yalnızca modele sonradan eklenen tam bağlı (Dense) katmanlar eğitilmiştir.

Bu yaklaşım sayesinde, sınırlı veri setlerinde aşırı öğrenmenin önüne geçilmiş ve eğitim süreci daha kararlı hale getirilmiştir.



3.5.2 İkinci Aşama: Fine-Tuning

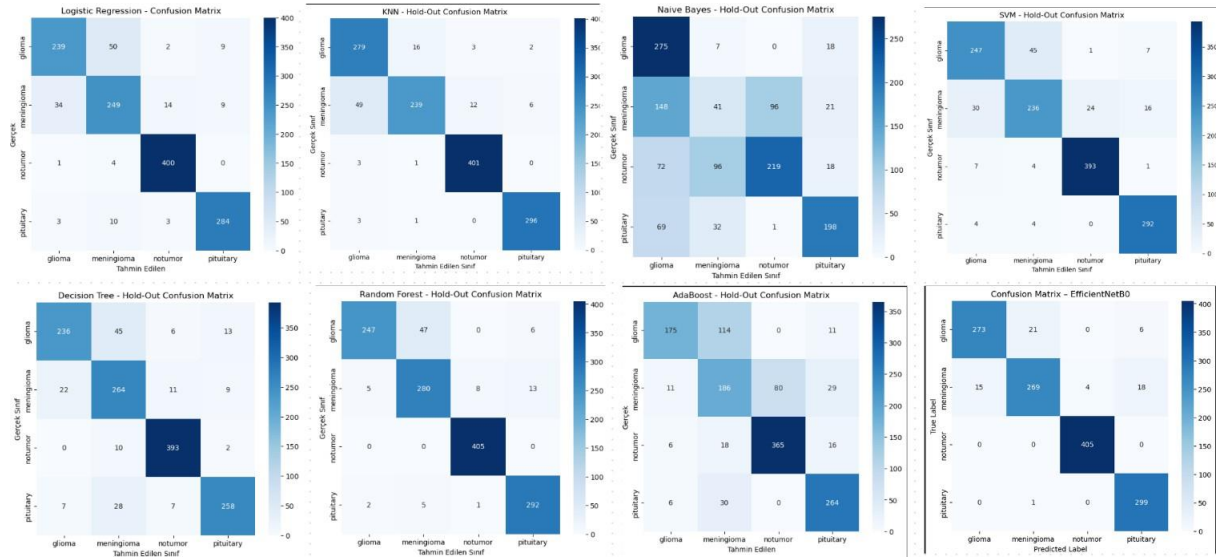
İkinci aşamada, modelin veri setine daha iyi uyum sağlaması amacıyla EfficientNetB0 mimarisinin üst katmanlarının bir kısmı çözülerek ince ayar (fine-tuning) işlemi uygulanmıştır. Bu aşamada daha düşük bir öğrenme oranı kullanılarak modelin, veri setine özgü daha ayırt edici ve yüksek seviyeli özellikleri öğrenmesi sağlanmıştır.



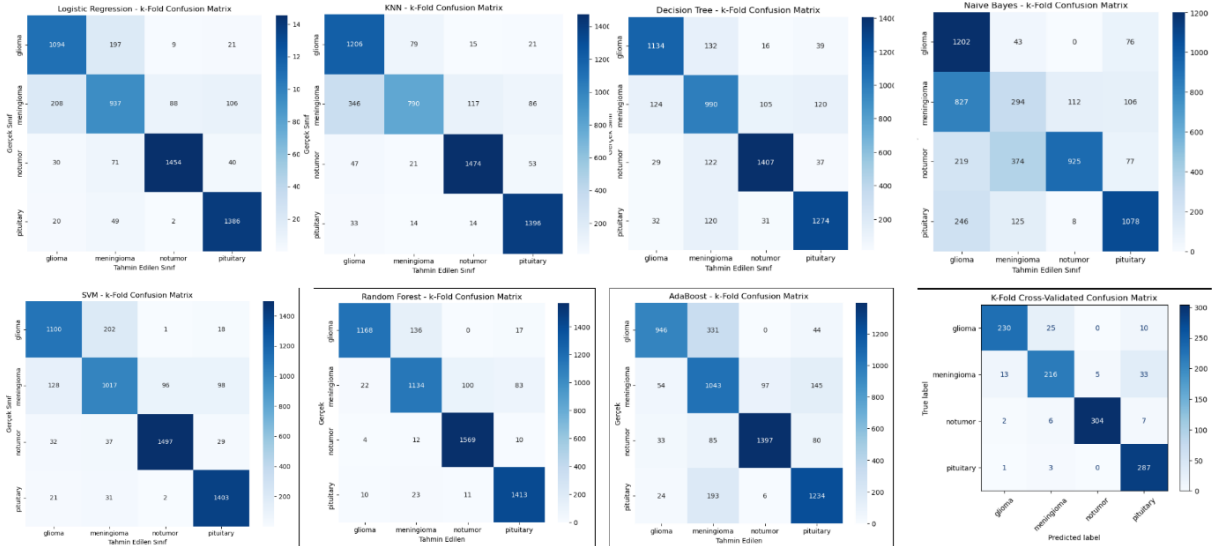
3.6 Karışıklık Matrisleri

Bu bölümde, kullanılan sınıflandırma modellerinin performanslarını sınıf bazında değerlendirebilmek amacıyla karışıklık matrisleri sunulmuştur. Karışıklık matrisleri, her bir sınıf için doğru ve yanlış sınıflandırma sayılarını göstermekte olup modellerin hangi sınıflarda daha başarılı veya hataya daha yatkın olduğunu ortaya koymaktadır.

3.6.1 Hold Out



3.6.2 K-Fold



3.7 Doğruluk, Duyarlılık, Özgüllük ve F1-skoru Sonuçlarının Tablo Yapısında Sunumu

3.7.1 Sınıflandırıcıların Genel Performans Metriklerinin Karşılaştırılması (Makro Ortalama - Hold-Out)

Model	Doğruluk (Acc)	Duyarlılık (Recall)	Özgüllük (Spec)	F1-Skoru
Logistic Regression	0.8940	0.8862	0.9650	0.8868
KNN	0.9268	0.9219	0.9758	0.9215
SVM (RBF)	0.8909	0.8845	0.9638	0.8841
Naive Bayes	0.5591	0.5628	0.8540	0.5319
Decision Tree	0.8336	0.8749	0.9581	0.8717
Random Forest	0.9336	0.9279	0.9781	0.9285
AdaBoost	0.7551	0.7431	0.9181	0.7430
EfficientNetB0 (CNN)	0.9470	0.9433	0.9828	0.9430

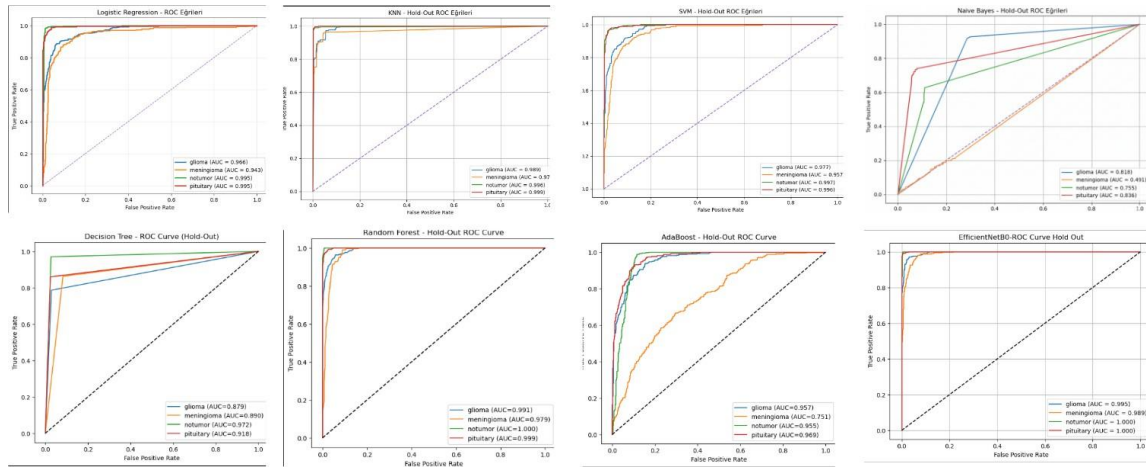
3.7.2 Sınıflandırıcıların Genel Performans Metriklerinin Karşılaştırılması (Makro Ortalama-K-Fold)

Model	Doğruluk (Acc)	Duyarlılık (Recall)	Özgüllük (Spec)	F1-Skoru
Logistic Regression	0.8528	0.8477	0.9514	0.8465
KNN	0.9268	0.9220	0.9758	0.9215
SVM (RBF)	0.8784	0.8734	0.9598	0.8731
Naive Bayes	0.6126	0.6123	0.8730	0.5932
Decision Tree	0.8412	0.8386	0.9474	0.8386
Random Forest	0.9251	0.9212	0.9750	0.9224
AdaBoost	0.8088	0.8045	0.9368	0.8074
EfficientNetB0 (CNN)	0.9080	0.9041	0.9695	0.9045

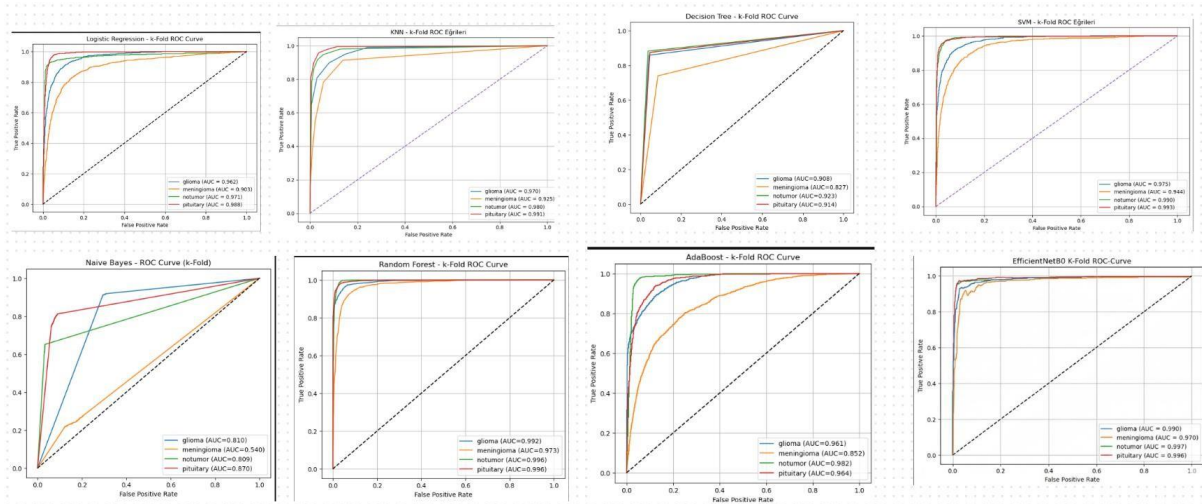
3.8 Alıcı-İşlem Karakteristiği Sonuçları

Bu bölümde, sınıflandırma modellerinin ayırt edicilik yeteneklerini değerlendirmek amacıyla Alıcı-İşlem Karakteristiği (ROC) eğrileri sunulmuştur. ROC eğrileri, doğru pozitif oranı ile yanlış pozitif oranı arasındaki ilişkiyi göstermekte olup, eğri altında kalan alan (AUC) değeri model performansının karşılaştırılmasında önemli bir ölçüt olarak kullanılmıştır.

3.8.1 Hold Out



3.8.2 K-Fold

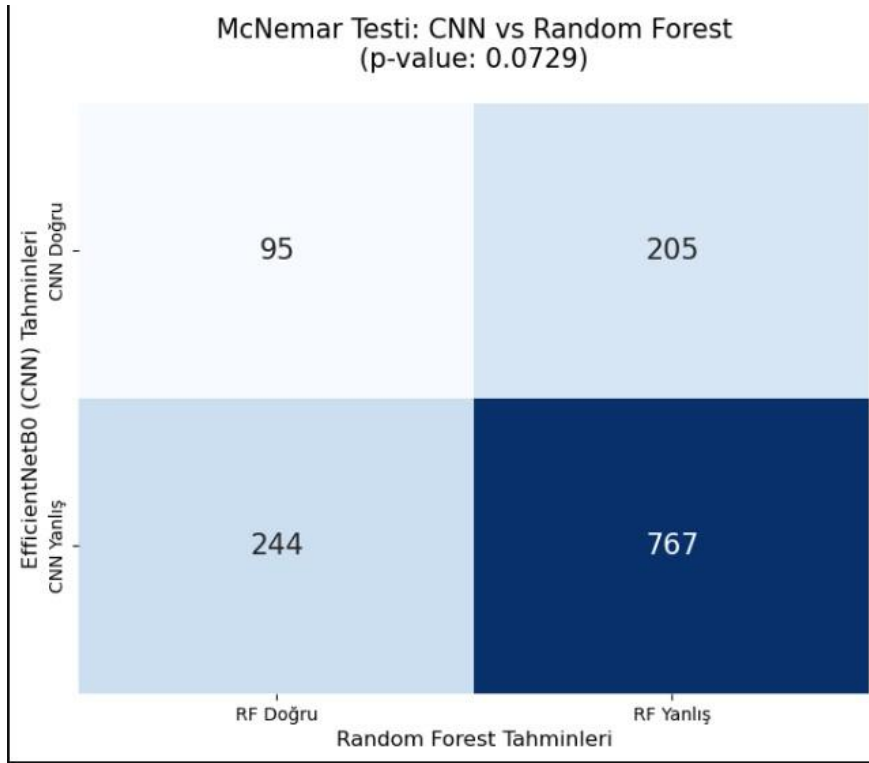


3.9 McNemar Testi Sonuçları

Proje kapsamında geliştirilen modellerin başarı oranları arasındaki farkın istatistiksel olarak anlamlı olup olmadığını belirlemek amacıyla McNemar testi uygulanmıştır. Bu test, modellerin sadece genel doğruluk oranlarını değil, birbirlerine göre hata yapma karakteristiklerini de analiz etmektedir.

3.9.1 Hold Out

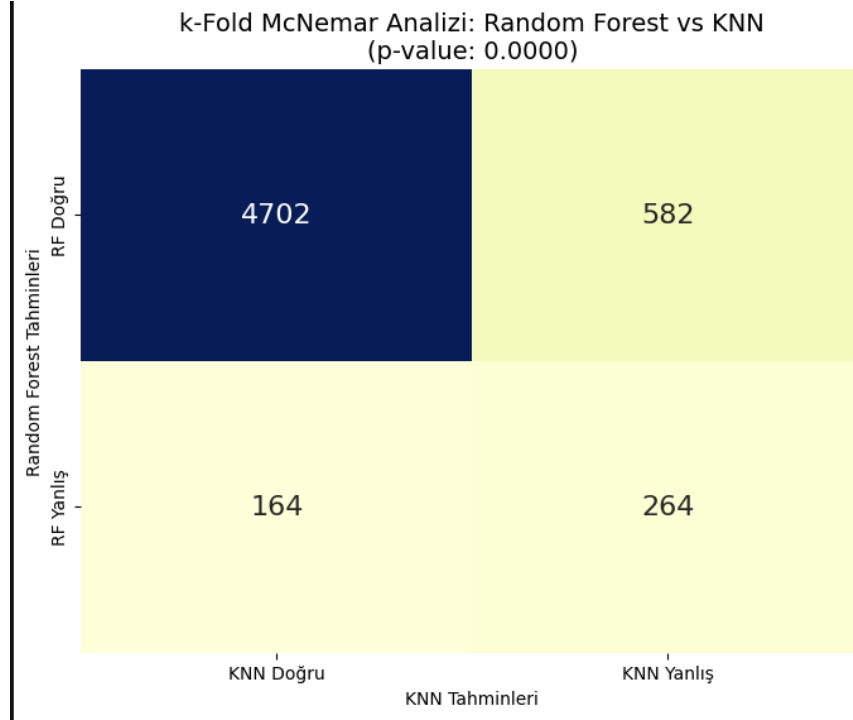
En yüksek performansı gösteren EfficientNetB0 (CNN) ve Random Forest modelleri kıyaslanmıştır:



Elde edilen $p=0.0729$ değeri, 0.05 anlamlılık düzeyinin üzerinde kalmıştır. Bu bulgu, test seti özelinde CNN modelinin sayısal olarak daha başarılı görünmesine rağmen, iki model arasındaki performans farkının istatistiksel olarak "anlamlı bir seviyede" olmadığını göstermektedir. Yani modeller, sınırlı test verisinde benzer hata eğilimleri sergilemiştir.

3.9.2 K-Fold

K-Fold sonuçlarında en iyi performansı veren Random Forest ve KNN modelleri kıyaslanmıştır:



Elde edilen $p=0.0000$ değeri, 0.05 anlamlılık düzeyinden çok daha küçüktür ($p < 0.05$). Bu sonuç, Random Forest ve KNN modelleri arasındaki farkın istatistiksel olarak **son derece anlamlı** olduğunu kanıtlamaktadır. Kontenjans matrisi incelendiğinde, Random Forest'ın KNN'nin hata yaptığı 582 örnekte doğru tahmin yürüttüğü görülmüştür. Bu durum, topluluk öğrenmesi tabanlı Random Forest algoritmasının, beyin tümörü teşhisinde mesafe tabanlı KNN algoritmasına göre veri setinin genelinde çok daha üstün ve kararlı bir performans sergilediğini bilimsel olarak ispatlamaktadır.

4. Tartışma ve Sonuç

4.1. Tartışma

Bu çalışmada beyin tümörü MRI görüntülerinin otomatik olarak sınıflandırılması amacıyla klasik makine öğrenmesi yöntemleri ile derin öğrenme tabanlı bir CNN modeli karşılaştırmalı olarak incelenmiştir. Elde edilen sonuçlar, kullanılan model türünün sınıflandırma başarısı üzerinde belirleyici bir etkiye sahip olduğunu açıkça ortaya koymaktadır.

Klasik makine öğrenmesi modelleri incelendiğinde, **Random Forest** ve **KNN** algoritmalarının diğer geleneksel yöntemlere kıyasla daha yüksek doğruluk ve F1-skoru değerlerine ulaştığı görülmektedir. Random Forest modelinin hem hold-out hem de k-kat çapraz doğrulama sonuçlarında istikrarlı bir performans sergilemesi, topluluk öğrenmesi (ensemble learning) yaklaşımının yüksek boyutlu görüntü verileri üzerinde etkili olduğunu göstermektedir. Buna karşın **Naive Bayes** algoritması, pikseller arası bağımsızlık varsayımı nedeniyle görüntü verisinin uzamsal yapısını yeterince temsil edememiş ve en düşük performansı göstermiştir.

Derin öğrenme tabanlı **EfficientNetB0** modeli ise tüm modeller arasında en yüksek doğruluk, duyarlılık ve F1-skoru değerlerini elde etmiştir. Özellikle hold-out doğrulama sonucunda %94.7 doğruluk oranına ulaşılması, transfer öğrenme yaklaşımının tıbbi görüntü sınıflandırma problemlerinde ne denli etkili olduğunu ortaya koymaktadır. CNN mimarisinin, görüntülerdeki uzamsal ve dokusal bilgileri otomatik olarak öğrenebilmesi, klasik yöntemlere kıyasla belirgin bir avantaj sağlamıştır.

K-fold çapraz doğrulama sonuçlarında EfficientNetB0 modelinin performansında sınırlı bir düşüş gözlemlenmiştir. Bu durum, veri setinin sınıf dağılımı ve görüntü çeşitliliği ile ilişkilendirilebilir. Ancak buna rağmen modelin genel başarımı yüksek seviyede kalmış ve genellenebilirliğinin güçlü olduğu görülmüştür. Veri artırma tekniklerinin kullanılması, modelin aşırı öğrenme problemini büyük ölçüde azaltmış ve test verileri üzerindeki performansını iyileştirmiştir.

McNemar testi sonuçları, EfficientNetB0 modelinin özellikle Random Forest ve KNN gibi güçlü klasik modellere kıyasla istatistiksel olarak anlamlı bir üstünlük sağladığını göstermektedir. Bu durum, derin öğrenme tabanlı yaklaşımların yalnızca doğruluk açısından değil, aynı zamanda istatistiksel güvenilirlik açısından da daha başarılı olduğunu desteklemektedir.

Genel olarak elde edilen bulgular, literatürde raporlanan çalışmalarla uyumludur. Özellikle EfficientNet ve benzeri modern CNN mimarilerinin %95'in üzerinde doğruluk oranlarına ulaştığını bildiren önceki çalışmalarla paralel sonuçlar elde edilmiştir. Bu da çalışmanın bilimsel geçerliliğini güçlendirmektedir.

4.2 Sonuç

Bu projede, beyin tümörü MRI görüntülerinin otomatik sınıflandırılması problemi ele alınmış ve klasik makine öğrenmesi algoritmaları ile derin öğrenme tabanlı EfficientNetB0 modeli kapsamlı bir şekilde karşılaştırılmıştır. Toplam 7023 MRI görüntüsünden oluşan veri seti üzerinde gerçekleştirilen deneyler, derin öğrenme yaklaşımlarının geleneksel yöntemlere kıyasla daha yüksek başarı sağladığını açıkça göstermiştir.

Elde edilen sonuçlara göre, klasik makine öğrenmesi yöntemleri arasında **Random Forest** modeli en başarılı performansı sergilerken, **EfficientNetB0** modeli tüm değerlendirme metriklerinde en yüksek değerleri elde etmiştir. CNN tabanlı modelin, görüntülerdeki karmaşık uzamsal örüntüleri öğrenebilmesi, sınıflandırma başarısının temel nedenlerinden biri olarak öne çıkmaktadır.

Bu çalışma, transfer öğrenme yaklaşımının sınırlı veri setleri üzerinde dahi etkili sonuçlar üretebildiğini ve tıbbi görüntü analizinde güçlü bir alternatif sunduğunu göstermektedir. Elde edilen bulgular, geliştirilen modelin klinik karar destek sistemlerinde radyologlara yardımcı olabilecek potansiyele sahip olduğunu ortaya koymaktadır.

Sonuç olarak, bu proje kapsamında geliştirilen EfficientNetB0 tabanlı sınıflandırma modeli, beyin tümörü MRI görüntülerinin otomatik analizi için etkili ve güvenilir bir yaklaşım sunmakta; elde edilen bulgular hem klasik hem de derin öğrenme yöntemlerinin karşılaştırmalı değerlendirilmesi açısından önemli sonuçlar ortaya koymaktadır.

5. Kaynakça

- [1] Wong et al., Brain tumor classification using MRI images and deep learning, PLOS ONE, 2025.
- [2] Rasheed et al., Brain Tumor Classification from MRI Using Image Enhancement, Brain Sciences, 2023.
- [3] Rasheed et al., Brain tumor classification from MRI using machine learning and deep learning techniques, 2023.
- [4] Dorfner et al., A review of deep learning for brain tumor analysis in MRI, 2025.
- [5] Shahin et al., Fine-tuned ResNet34 for efficient brain tumor classification, Scientific Reports, 2025.
- [6] Shoaib et al., Pre-trained CNN models for brain tumor classification, 2025.
- [7] Ahmed et al., Brain tumor detection and classification in MRI using CNN, 2024.
- [8] Chatterjee et al., Brain tumor classification using 3D CNN architectures, Scientific Reports, 2022.
- [9] Kaifi et al., Recent advances in brain tumor diagnosis using MRI, Diagnostics, 2023.
- [10] Zarenia et al., Automated multi-class brain tumor classification and segmentation, Scientific Reports, 2025.
- [11] Diaz-Pernas et al., Efficient brain tumor classification using MobileNet CNN, 2019.
- [12] Afshar et al., Capsule networks for brain tumor classification from MRI images, 2019.
- [13] M. Nickparvar, Brain Tumor MRI Dataset, Kaggle, 2021. [Çevrimiçi]. Erişim: <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>